

Documento 1 - Sistema de Deteccion de Similitud Documental

Documento de prueba para SierraScan - uso academico.

Introduccion

La revision de documentos academicos es una actividad importante dentro de una institucion universitaria. Cuando un docente recibe varios trabajos de estudiantes, puede resultar dificil identificar manualmente si existen fragmentos copiados o textos demasiado parecidos entre si. Por esta razon, las herramientas de apoyo para detectar similitud documental pueden reducir el tiempo de revision y mejorar la calidad del proceso academico.

Desarrollo del sistema

El sistema propuesto permite cargar archivos PDF, convertirlos a texto plano y preparar su contenido para el analisis. Primero se extrae el texto del documento, despues se normaliza a minusculas, se eliminan acentos, simbolos innecesarios y palabras comunes. Posteriormente, el texto limpio se representa mediante TF-IDF para transformar las palabras en valores numericos que puedan ser comparados.

La comparacion se realiza mediante similitud de coseno. Esta medida permite calcular que tan parecidos son dos documentos segun la orientacion de sus vectores de palabras. Si dos documentos comparten muchos terminos importantes, el porcentaje de similitud aumenta. Si los documentos tratan temas distintos o comparten pocas palabras relevantes, el porcentaje disminuye.

Importancia academica

Este tipo de sistema no reemplaza el criterio del docente, pero sirve como apoyo inicial para encontrar coincidencias sospechosas. Un porcentaje alto no significa automaticamente que exista plagio, sino que el documento debe revisarse con mayor detalle. De esta manera, el sistema funciona como una herramienta auxiliar para fortalecer la integridad academica.